MLDS

Hw3 Report

R05725004 資管碩二 曾千蕙

(1) DQN model

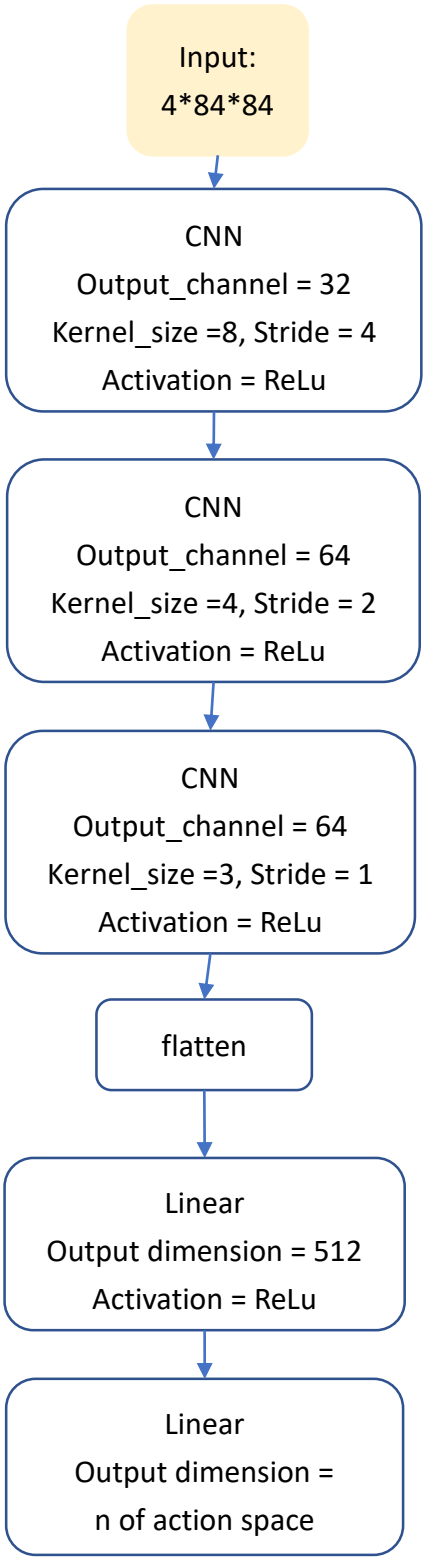

左圖為用來計算(state, action)的 value 的模型，input 為 environment 輸出的圖片(state), output 為在這個 state 的條件下各個 action 的 value 值。

共訓練 3,000,000 steps
Optimizer = RMSProp
Learning rate = 0.0001
GAMMA = 0.99
relay memory 大小 = 10000
target model update frequency = 1 次 / 1000 steps
online model update frequency = 1次 / 4 steps
Learning start: 10000 steps 之後

Random action 的機率:
在 1,000,000 steps 內從 0.99 遞減到 0.05, 以已執行過的 steps 數 / 1000000 的比例線性遞減

訓練表現:

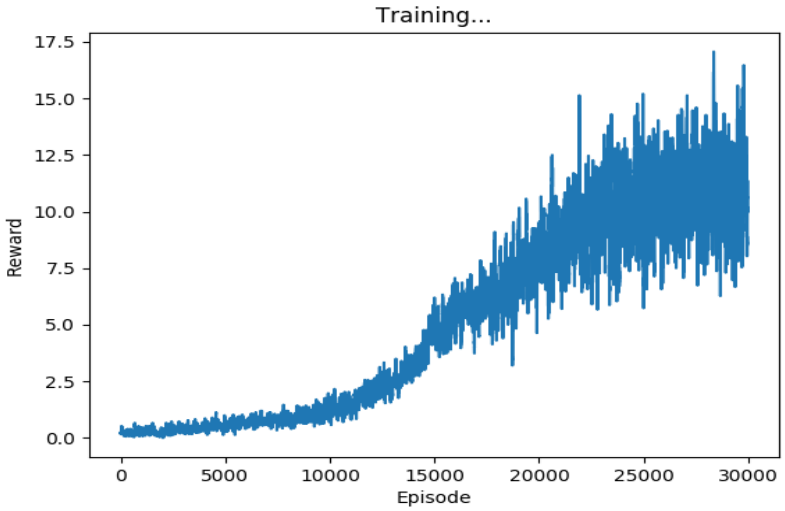

(2) Policy Gradient

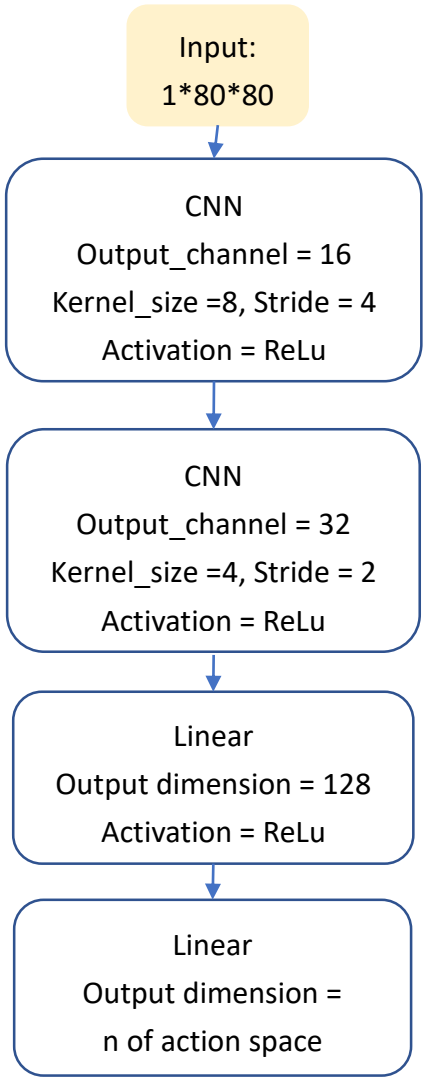

左圖為 Policy network 的架構
Input 是前處理後的灰階 state,
output 是在這個 state 的條件之下各個 action 的機率值

Optimizer : RMSProp
Learning rate = 0.0001

GAMMA = 0.99

訓練表現:

(2) 實驗:

選擇 exploration schedule 做為實驗調整的參數, 試著調整隨機選擇 action 的機率，分別試了從 90%遞減到 5%、99%遞減到 5%、99%遞減到 1%、99%遞減到 10%的設定。之所以選擇這個設定是因為一開始這個 exploration rate 設得較低時，發現訓練不太起來，推測是因為一開始的模型由於尚未經過訓練，所以給的預測通常不太有用，且一開始由於很容易就死掉了，能觀察到的 state 也有限，若使用模型的預測，感覺得到的(state, action) pair 可能變化太少了，無法讓 agent 對這個環境有更多的認識，因此一開始的 exploration rate 應該要設定高一點，藉由 random 決定動作再觀察 reward, 讓 agent 更容易學到怎樣的 action 的 reward 應該要比較高。另外，關於 exploration rate 最後應該固定到多少較合適，從圖中可以看到從 99%降到 1%的設定(淺橘色線)的表現最好，因為到了後期用 random 選動作比起用 model 預測動作容易死掉，所以 reward 比較難上升，我覺得可能因為這個遊戲並不是太複雜，所以不需要花太多力氣的 exploration 上面，所以最後固定的 exploration rate 不需要太高，讓 model 盡量在已知的情況下得到最高的 reward 可能比較好。